

Regularización de Modelos

Los modelos lineales suelen ser más fáciles de interpretar y tiene mayor capacidad de generalización al ser menos flexibles. Es bien sabido que a más variables el modelo es más flexible y por ende su varianza es mayor. Por ello vamos a analizar métodos de regularización de los modelos de ajuste que logren que la cantidad de variables predictoras sea menor, y así obtener una reducción de la varianza del modelo y su consiguiente capacidad de generalización

- **Regularización: Regresión Contraída**

El primer método de regularización o encogimiento (*shrinkage*) es el de Regresión Contraída, o *Ridge Regression* en inglés. La regresión contraída mantiene todas las variables predictores pero disminuye su influencia en la predicción.

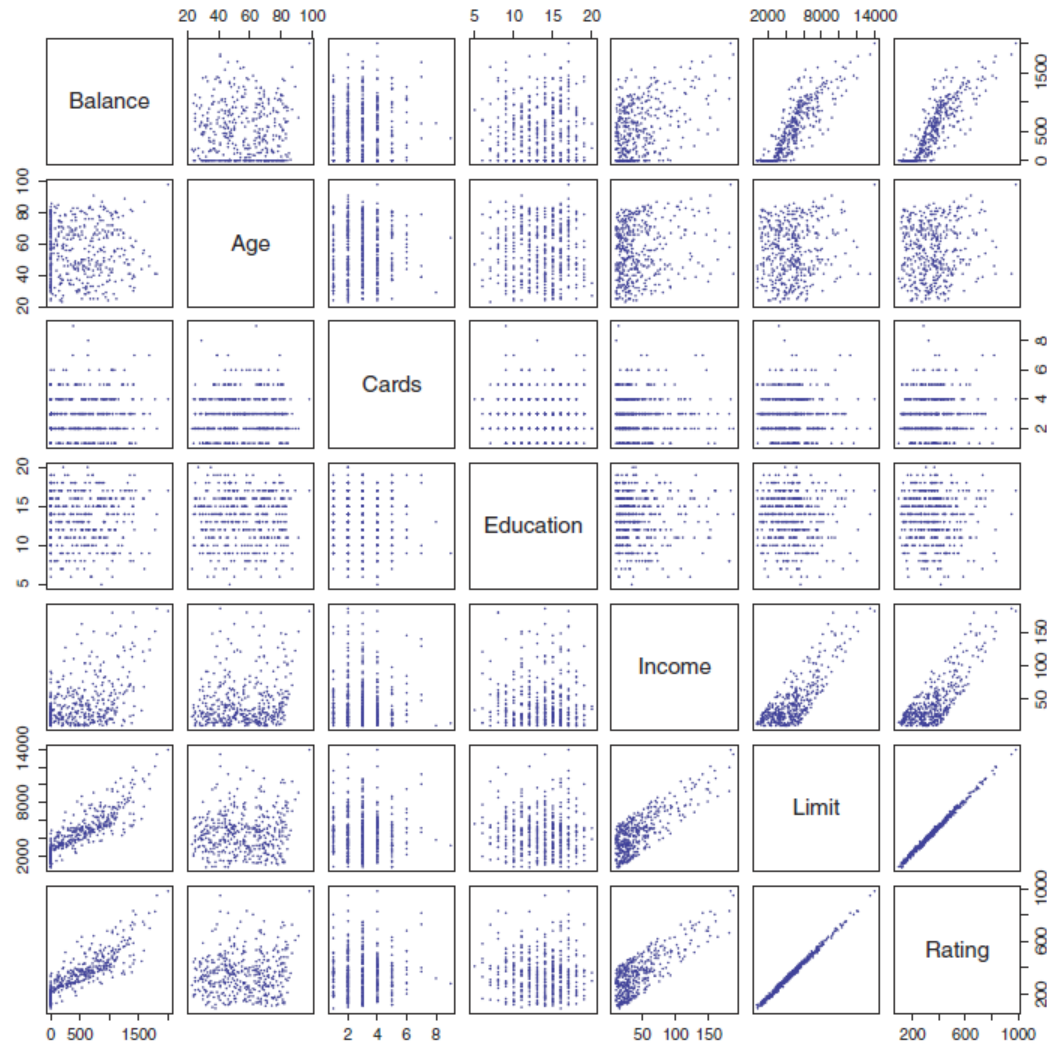
En RL queremos minimizar esta función por Camín
$$RSS = \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2$$

En RL Contraída le adicionamos :



$$\sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p \beta_j^2 = RSS + \lambda \sum_{j=1}^p \beta_j^2$$


Matriz de Diagramas de dispersión (covarianzas)

Balance ~ age, cards, education, income, limit, rating, vender, student, status, ethnicity



Balance ~ age, cards, education , income , limit, rating , vender, student, status , ethnicity



- Regresión LASSO

La desventaja de la regresión contraída es que contiene TODOS los predictores. La penalización puede llegar a contraer todos los coeficientes β_j a un valor cercano a cero, pero nunca hacerlos llegar exactamente a cero.

En LASSO se reemplaza la penalización $|\beta_j|^2$ por $|\beta_j|$

$$\sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p |\beta_j| = \text{RSS} + \lambda \sum_{j=1}^p |\beta_j|$$

Esta nueva penalización si consigue llevar algunos coeficientes a cero, consiguiendo así un modelo con menor varianza y más fácil de interpretar.



